



INFORME

Predicción de Abandono de Clientes en ABC Multistate Bank

Alumnos:

- Miguel Ángel Nova
- Martina Morales
- Ivania Becerra

Profesor: Francisco Alfaro

Índice.

Resumen Ejecutivo.....	3
1. Introducción	3
2. Análisis Exploratorio de Datos	3
2.1 Descripción general y traducción de variables	3
2.2 Análisis univariado	4
2.3 Análisis bivariado	4
2.4 Detección de valores atípicos	6
2.5 Decisiones de tratamiento	6
3. Preparación de los Datos	7
3.1 División train/test estratificada	7
3.2 Codificación y escalado sin fuga de datos.....	7
3.3 Estrategia frente al desbalance.....	7
4. Fase de Modelado.....	7
4.1 Regresión Logística (baseline).....	7
4.2 Árbol de Decisión	7
4.3 Random Forest.....	7
4.4 Gradient Boosting	7
5. Evaluación de Modelos	8
6. Umbral Óptimo y Métricas de Negocio	8
7. Análisis de Negocio y Recomendaciones	10
7.1 Factores más influyentes	10
7.2 Acciones concretas por factor	11
7.3 Plan de 90 días para reducir el abandono un 10%.....	11
7.4 Integración en una campaña de retención	11
8. Conclusiones	11

Resumen Ejecutivo

Ante el aumento de clientes que cierran sus cuentas en ABC Multistate Bank, construimos y comparamos cuatro modelos de clasificación para predecir el **churn** —que afecta al 20,4% de una cartera de 10.000 clientes— y traducir esa predicción en acciones de retención. El análisis exploratorio identificó a la edad, el número de productos y la inactividad como las señales más fuertes de fuga. Entrenamos los modelos dentro de pipelines sin fuga de datos, ajustamos sus hiperparámetros por validación cruzada optimizando ROC-AUC y tratamos el desbalance con ponderación de clases y calibración de umbral. El modelo seleccionado es **Gradient Boosting**, con el mejor ROC-AUC (0,87) y la mayor precisión.

Recomendamos **operar el modelo con un umbral de 0,23 en lugar de 0,5**, priorizando el recall: capturamos cerca del 74% de los clientes que realmente abandonarán, porque un falso negativo cuesta mucho más que una falsa alarma. En lo operativo, proponemos un plan de 90 días con scoring mensual, priorización por riesgo × valor e intervenciones focalizadas —segmento senior, auditoría de sobreventa de productos, reactivación de inactivos y revisión de la oferta en Alemania—, integrado al CRM con un ciclo de retroalimentación. Con este enfoque, la meta de **reducir el abandono un 10% el próximo trimestre** es alcanzable y medible.

1. Introducción

Como equipo de datos de ABC Multistate Bank, enfrentamos el aumento de clientes que cierran sus cuentas: el fenómeno del **churn** o fuga. Perder un cliente golpea dos veces, porque se van los ingresos que generaba y, además, captar un reemplazo cuesta varias veces más que retener a quien ya está. La clave es el factor tiempo: si detectamos las señales de fuga antes de que el cliente concrete su salida, el banco puede actuar de forma preventiva y conservar la relación.

El objetivo de este trabajo es construir y comparar **cuatro modelos de clasificación** que predigan la probabilidad de abandono de cada cliente, identificar los factores que más influyen en esa decisión y traducirlos en acciones de retención concretas y medibles.

2. Análisis Exploratorio de Datos

2.1 Descripción general y traducción de variables

El dataset reúne **10.000 clientes** descritos con 12 variables, sin valores nulos ni duplicados. La variable `id\_cliente` es solo un identificador y `abandono` es la variable objetivo; las diez restantes son predictores demográficos, financieros y de relación con el banco. A solicitud del profesor, traducimos todas las variables del inglés original al español, según la equivalencia de la Tabla 1.

Original (inglés)	Español	Descripción
customer_id	id_cliente	Identificador único (no se modela)
credit_score	puntaje_credito	Puntaje crediticio
country	país	País (Francia, España, Alemania)
gender	género	Género (Femenino, Masculino)

age	edad	Edad
tenure	antigüedad	Años de relación con el banco
balance	saldo	Saldo de la cuenta
products_number	numero_productos	Número de productos contratados
credit_card	tarjeta_credito	Tiene tarjeta de crédito (1/0)
active_member	miembro_activo	Es miembro activo (1/0)
estimated_salary	salario_estimado	Salario anual estimado
churn	abandono	Variable objetivo (1 = abandonó)

Tabla 1. Traducción de variables al español.

2.2 Análisis univariado

La variable objetivo presenta un **marcado desbalance**: solo el **20,4%** de los clientes abandona, frente al 79,6% que permanece (Figura 1). Por eso descartamos la **accuracy** como métrica —un modelo trivial que prediga "nadie se va" acertaría el 80% sin aportar valor— y priorizamos ROC-AUC, precisión, recall y F1. Entre las variables numéricas observamos una edad con sesgo positivo, un saldo bimodal (con unos 3.617 clientes de saldo cero) y un salario prácticamente uniforme.




Figura 1. Distribución de la variable objetivo: solo el 20,4 % abandona.

2.3 Análisis bivariado

Al cruzar cada predictor con el abandono aparecen los patrones más relevantes. La **edad** es el factor más discriminante (44,8 años promedio en quienes se van vs 37,4 en quienes permanecen). Por

geografía, **Alemania duplica la fuga (32,4%)** respecto de Francia y España (~16%), como muestra la Figura 2.




Figura 2. Tasa de abandono por país: Alemania duplica el promedio.

El hallazgo más fuerte es la **relación no lineal con el número de productos**: con 2 productos la fuga es mínima (7,6%), pero con 3 y 4 escala a **82,7%** y **100%** (Figura 3). Ninguna técnica lineal captura bien este patrón, lo que anticipa la ventaja de los modelos de árbol.




Figura 3. Abandono por número de productos: relación fuertemente no lineal.

La matriz de correlación (Figura 4) confirma numéricamente lo anterior: la edad (0,29) y el saldo (0,12) son las correlaciones positivas más fuertes con el abandono, y la condición de miembro activo (−0,16) el principal factor protector. La correlación de Pearson solo mide relaciones lineales, por eso `numero\_productos` aparece débil pese a ser clave.




Figura 4. Matriz de correlación entre variables y el abandono.

2.4 Detección de valores atípicos

Con el método del rango intercuartílico (IQR) detectamos pocos valores atípicos: la **edad** concentra la mayoría (359 casos, 3,59%, correspondientes a clientes reales de 63 a 92 años), seguida de `numero\_productos` (60 casos) y `puntaje\_credito` (15). Las variables `antiguedad`, `saldo` y `salario\_estimado` no presentan outliers.

2.5 Decisiones de tratamiento

- **Valores faltantes:** no hay imputación que hacer, el dataset no tiene nulos.
- **Valores atípicos:** los conservamos. Los outliers de edad son clientes mayores legítimos y, además, el segmento de mayor propensión a la fuga; los modelos de árbol son robustos frente a ellos.
- **Variables:** eliminamos `id\_cliente`, codificamos `país` y `género`, y escalamos las numéricas.

3. Preparación de los Datos

3.1 División train/test estratificada

Dividimos en **80% entrenamiento (8.000)** y **20% prueba (2.000)** con muestreo estratificado, manteniendo la proporción de fuga (~20,4%) idéntica en ambos conjuntos para no sesgar las métricas.

3.2 Codificación y escalado sin fuga de datos

Codificamos `país` y `género` con One-Hot Encoding (base Francia/Femenino) y escalamos las numéricas con `StandardScaler`, todo dentro de un `ColumnTransformer` encapsulado en el pipeline. Así el preprocesamiento aprende sus parámetros **solo con el entrenamiento de cada partición** de la validación cruzada, evitando la **fuga de datos** (data leakage). Quedan 11 variables predictoras.

3.3 Estrategia frente al desbalance

Con ~20% de fuga evitamos generar datos sintéticos (SMOTE) y atacamos el desbalance en dos niveles: `class\_weight=balanced` en Regresión Logística, Árbol y Random Forest, y —en Gradient Boosting, que no admite ese parámetro— mediante el **ajuste del umbral de decisión** (Sección 6), el lugar metodológicamente correcto para inyectar el costo del negocio.

4. Fase de Modelado

Entrenamos cuatro modelos, cada uno como un pipeline con **validación cruzada de 5 particiones optimizando ROC-AUC**, la métrica principal.

4.1 Regresión Logística (baseline)

Modelo de referencia por su interpretabilidad (ROC-AUC de validación cruzada 0,766). Sus coeficientes, sobre variables estandarizadas y leídos como **odds ratios**, confirman los hallazgos del EDA: `país\_Alemania` (OR 2,29) y `edad` (OR 2,23) elevan el riesgo, mientras `miembro\_activo` (OR 0,41) es el mayor factor protector.

4.2 Árbol de Decisión

Mejor configuración: `max\_depth=6`, `min\_samples\_split=50`, `min\_samples\_leaf=20` (ROC-AUC CV 0,835). Captura relaciones no lineales que la logística no ve; como modelo único, presenta más varianza que los ensambles.

4.3 Random Forest

Mejor configuración: `n\_estimators=500`, `max\_depth=8`, `min\_samples\_leaf=5`, `max\_features=sqrt` (ROC-AUC CV 0,860). Al promediar 500 árboles sobre submuestras de datos y variables, reduce la varianza del árbol individual.

4.4 Gradient Boosting

Mejor configuración: `learning\_rate=0,05`, `max\_depth=3`, `n\_estimators=200`, `subsample=0,8` (**ROC-AUC CV 0,865, el más alto**). Construye árboles secuencialmente, cada uno corrige los errores del

anterior, lo que le permite modelar interacciones no lineales (como la de `numero\_productos`, `edad` y `miembro\_activo`) con menor sesgo.

5. Evaluación de Modelos

Evaluamos los cuatro modelos sobre el conjunto de prueba (Tabla 2, Figura 5). **Gradient Boosting** obtiene el mejor ROC-AUC (0,873) y la mejor precisión (0,796). Con umbral 0,5 su recall es el más bajo (0,49) porque, a diferencia de los demás, no lleva ponderación de clases; pero su AUC superior indica que sus probabilidades están mejor ordenadas, algo que aprovechamos ajustando el umbral. Por su poder discriminativo y precisión, **seleccionamos Gradient Boosting como modelo final**.

Modelo	ROC-AUC	Precisión	Recall	F1
Gradient Boosting	0,873	0,80	0,49	0,61
Random Forest	0,865	0,55	0,72	0,62
Árbol de Decisión	0,842	0,45	0,78	0,57
Regresión Logística	0,777	0,39	0,70	0,50

Tabla 2. Desempeño de los modelos en el conjunto de prueba (umbral 0,5).




Figura 5. Comparación de ROC-AUC: Gradient Boosting es el mejor modelo.

6. Umbral Óptimo y Métricas de Negocio

El umbral por defecto de 0,5 rara vez es óptimo con clases desbalanceadas. Barriando umbrales sobre las probabilidades del modelo, el que **maximiza el F1** es **0,23** (Figura 6), donde el recall sube de 0,49 a 0,74 con una caída controlada de la precisión (Tabla 3).

Umbral	Precisión	Recall	F1
0,20	0,51	0,76	0,61
0,23 (óptimo)	0,57	0,74	0,64
0,30	0,63	0,65	0,64
0,50 (por defecto)	0,80	0,49	0,61
0,70	0,91	0,34	0,49

Tabla 3. Desempeño del modelo final bajo distintos umbrales.




Figura 6. Precisión, Recall y F1 según el umbral de decisión.

La matriz de confusión al umbral elegido (Figura 7) muestra el resultado concreto: de los **407 clientes que efectivamente abandonan, detectamos 300**. Priorizamos el recall porque el error más costoso es el **falso negativo** —perder un cliente y su valor futuro— frente al **falso positivo**, que solo cuesta una acción de retención. El umbral exacto se calibra según el presupuesto: con más recursos se puede bajar aún más.




Figura 7. Matriz de confusión del modelo final (umbral 0,23).

7. Análisis de Negocio y Recomendaciones

7.1 Factores más influyentes

El modelo confirma que la decisión de fuga no es aleatoria: **tres factores concentran cerca del 77%** de la importancia (Figura 8): la **edad** (~38%), el **número de productos** (~28%) y la **actividad** del cliente (~11%), seguidos del saldo y la geografía.




Figura 8. Importancia de las variables según el modelo final.

7.2 Acciones concretas por factor

- **Segmento senior (edad):** atención preferencial a mayores de 40, asesoría humana y productos de protección patrimonial.
- **Sobreventa de productos:** frenar el cross-selling agresivo en clientes con 2 productos y desplegar retención activa para quienes tienen 3 o más.
- **Reactivar inactivos:** alertas si un cliente no transacciona en 30 días y beneficios de uso (cashback) para reengancharlo.
- **Mercado alemán:** benchmarking contra competidores locales y revisión de tasas y oferta de valor.

7.3 Plan de 90 días para reducir el abandono un 10%

1. **Scoring mensual:** pasar toda la base activa por el modelo con el umbral calibrado (0,23).
2. **Priorización riesgo × valor:** atender primero a los clientes de alta probabilidad y alto saldo.
3. **Despliegue con prueba A/B:** acciones al 80% de los clientes en riesgo y 20% de control para medir el efecto real.
4. **Monitoreo de ROI:** comparar el costo de los incentivos con el capital retenido.

7.4 Integración en una campaña de retención

Automatizamos el **scoring semanal en el CRM**; si la probabilidad de fuga supera 0,23, se genera un ticket de "Alerta de Fuga" para que un asesor actúe. Un **ciclo de retroalimentación** registra el resultado de cada campaña y permite **reentrenar el modelo semestralmente** para adaptarlo a los nuevos comportamientos del mercado.

8. Conclusiones

El análisis realizado permitió comprobar que el abandono de clientes en ABC Multistate Bank es un fenómeno predecible mediante técnicas de clasificación supervisada. La comparación entre distintos modelos evidenció que existen patrones consistentes en el comportamiento de los clientes que permiten anticipar la fuga antes de que esta ocurra, generando una oportunidad concreta para desarrollar estrategias preventivas de retención.

Entre los modelos evaluados, Gradient Boosting presentó el mejor desempeño predictivo, alcanzando el mayor nivel de capacidad discriminativa y precisión frente a las demás alternativas analizadas. Este resultado demuestra que los enfoques basados en ensambles y relaciones no lineales ofrecen ventajas relevantes para modelar fenómenos complejos como el churn bancario.

El estudio identificó que la edad, el número de productos contratados y el nivel de actividad del cliente constituyen los factores más influyentes sobre la probabilidad de abandono. En particular, se observó que ciertos segmentos presentan mayor exposición al riesgo de fuga, lo que permite orientar futuras decisiones comerciales y programas de fidelización de manera más focalizada.

La calibración del umbral de decisión demostró ser un elemento clave para maximizar el valor del modelo desde una perspectiva de negocio. Al ajustar el umbral de clasificación se logró aumentar significativamente la capacidad de detectar clientes con riesgo de abandono, priorizando la reducción de

falsos negativos y alineando el desempeño técnico con los costos reales asociados a la pérdida de clientes.

Finalmente, el proyecto evidencia que la analítica predictiva puede transformarse en una herramienta operativa de gestión comercial cuando se integra con procesos de seguimiento y acciones concretas de retención. La propuesta de implementación mediante scoring periódico, segmentación por riesgo y monitoreo continuo entrega una base sólida para reducir el abandono y fortalecer la relación de largo plazo con los clientes.